

Hybrid LLM Routing Policy

1. 개요

LLM 모델은 동일한 규모라 하더라도 정확도, 지연시간, 출력량, 응답 안정성 등 특성이 다르게 나타난다.

따라서 단일 모델을 고정적으로 사용하는 방식 보다, 서비스 목적과 요청 특성에 따라 적절한 모델을 선택할 수 있는 **Hybrid Routing** 전략이 필요하다.

본 문서는 모델 평가 결과를 기반으로 모델군(**Model Tier**)을 분류하고, 서비스 기능 및 운영 조건에 따라 적합한 **Routing Rule**과 **Routing Policy**를 생성하기 위한 기준을 정의한다.

2. 적용 범위

구분	내용
정책 수준	Rule-based Routing
적용 환경	Local / On-prem / API 기반 LLM 환경
평가 기준	Accuracy, Latency, Output Token, Failure Rate
대상 서비스	챗봇, QA, 문서 요약, SQL 생성, RAG
제외 범위	학습형 Routing, Multi-Agent Orchestration

3. Model Tier 정의

Tier	역할	특징	목적	예시 모델
Lightweight	Fast Path	low latency / low cost	실시간 응답, FAQ	Phi-3, Qwen 3B
Standard	General Path	balanced	일반 QA, 업무 질의	Llama 3, Qwen 8B
Advanced	Accurate / Escalation	high accuracy / reasoning	고난도 추론, 검증	GPT-OSS-120b, GPT-4o, Claude Opus
Long Context	Context Path	긴 문맥 처리	문서 QA, RAG	Kimi
Structured	Structured Output Path	format 안전성	SQL/JSON 생성	

4. 서비스 기능별 권장 모델 전략

서비스 기능	요구사항	권장 Tier
일반 FAQ	빠른 응답	Lightweight
실시간 운영 챗봇	SLA 우선	Lightweight
일반 업무 QA	균형형 응답	Standard
정책/규정 QA	정확도 우선	Advanced
보고서 생성	긴 reasoning	Advanced
SQL/JSON 생성	구조화 출력	Structured
문서 요약	긴 출력 처리	Standard / Advanced
RAG 기반 문서 QA	긴 문맥	Long Context
회의록 분석	context 유지	Long Context
재검증 요청	신뢰성 확보	Advanced

5. Routing Rule 상세

Rule ID	조건	Route	운영 옵션
R-01	일반 FAQ / 단순 질의	Lightweight Path	즉시 응답
R-02	SLA / 실시간 응답 필요	Lightweight Path	p95 latency 모니터링
R-03	일반 업무 질의	Standard Path	기본 응답
R-04	정확도 우선 요청	Advanced Path	Timeout guard 적용
R-05	고난도 추론 / 복합 reasoning	Advanced Path	Reasoning 우선
R-06	긴 문서 기반 QA	Long Context Path	Context 유지
R-07	SQL/JSON 생성	Structured Path	Format validation
R-08	출력량 과다 예상	Token-Control Path	max_tokens 적용
R-09	timeout 발생	Fallback Path	대체 모델 호출
R-10	parse fail 발생	Retry Path	strict prompt 재시도
R-11	신뢰도 낮음 / 재검증 필요	Escalation Path	Advanced Tier 재검증

R-12	API 실패	Fallback Path	대체 모델 호출
R-13	모델 성능 차이 미미	Efficiency Path	latency/cost 우선 선택

6. Threshold (정책 발동 조건)


항목	기준
Fast Path 기준	p95 latency 기준 이하
Accurate Path 기준	정확도 차이 threshold 이상
Token Control 기준	output token threshold 초과
Timeout 기준	응답시간 threshold 초과
Parse Fail 기준	형식 불일치 발생
Fallback 기준	timeout / parse fail / API fail
Escalation 기준	신뢰도 낮음 또는 재검증 요청
Efficiency Path 기준	모델 성능 차이가 미미할 경우 latency 및 cost 효율 우선

7. Response Validation 및 예외 처리 정책

Validation 항목	목적	Validation 실패 시 대응
Parse Validation	JSON/SQL 형식 검증	Strict Retry 수행
Timeout Check	SLA 준수 여부 확인	Fallback Path 수행
Retry Validation	Retry 성공 여부 확인	Retry 횟수 제한 후 Escalation
Groundedness Check	문서 기반 응답 여부 검증	RAG 재검색 또는 Escalation
Hallucination Risk Check	허위 정보 가능성 최소화	Advanced Tier 재검증
Context Validation	긴 문맥 유지 여부 확인	Long Context Tier 전환

- + Response Validation은 Routing Rule에 따라 선택된 모델의 응답이 실제 서비스에서 사용 가능한지 확인하는 단계이다.
- + 이는 모델 선택 이후 발생할 수 있는 형식 오류, timeout, 근거 부족, 문맥 누락 등의 문제를 탐지하고, Retry·Fallback·Escalation 등 예외 처리 정책을 수행하기 위한 기준으로 활용된다.

8. Routing Flow



9. 성능 평가 체계

9.1 서비스 기능별 테스트 케이스 유형

서비스 기능	테스트 케이스 유형	목적
일반 FAQ	단순 질의응답	빠른 응답 및 기본 정확도 확인
실시간 운영 챗봇	짧은 운영 질의	SLA 및 latency 검증
일반 업무 QA	일반 업무 설명	균형형 응답 품질 검증
정책/규정 QA	근거 기반 질의	정확도 및 hallucination 최소화
보고서 생성	긴 응답 생성	reasoning 및 응답 품질 검증
SQL/JSON 생성	구조화 출력 요청	format 안정성 검증
문서 요약	긴 문서 입력	긴 출력 및 요약 품질 검증
RAG 기반 QA	문서 기반 질의	retrieval 및 groundedness 검증
회의록 분석	긴 context 입력	문맥 유지 및 정보 추출 검증

재검증 요청	기존 응답 검토	신뢰성 및 correction 검증
--------	----------	---------------------

9.2. 검증 기준 핵심 지표 설명

지표	설명	주 사용 목적
Accuracy	정답 또는 기대 결과를 얼마나 정확하게 생성했는지 평가	일반 QA, 정책 QA
Latency	요청 후 응답까지 걸리는 시간	실시간 챗봇, SLA
p95 Latency	전체 요청 중 95%가 이 시간 안에 응답되는 지표	SLA 및 운영 안정성
Timeout Rate	응답 제한 시간을 초과한 비율	Fast Path / Fallback 검증
Human Review Score	사람이 평가한 응답 품질 점수	업무 QA, 보고서 생성
Groundedness	응답이 실제 문서/근거 기반인지 평가	RAG, 정책 QA
Completeness	요청한 내용이 얼마나 빠짐없이 포함되었는지 평가	보고서 생성
Output Quality	응답 구조, 논리 흐름, 가독성 품질 평가	보고서 생성
Parse Success	JSON/SQL 등 구조화 출력이 정상 형식인지 평가	Structured Output
Format Validation	지정된 output schema를 준수하는지 검증	SQL/JSON 생성
Coverage	입력 문서의 핵심 내용을 얼마나 포함했는지 평가	문서 요약
Summary Quality	요약 과정에서 불필요한 정보 제거 및 핵심 유지 여부	문서 요약
Retrieval Hit Rate	검색된 문서가 실제 질문과 관련 있는 비율	RAG
Extraction Accuracy	특정 정보(Action Item 등)를 정확히 추출했는지 평가	회의록 분석
Reliability	응답 일관성 및 신뢰성 평가	재검증 요청
Correction Rate	기존 응답 오류를 얼마나 잘 수정했는지 평가	재검증 요청

Cost per 1K Tokens	1K token당 비용	비용 효율 분석
Token Efficiency	token 대비 성능 효율	Lightweight 우선 판단
Cost Efficiency	비용 대비 응답 품질	Routing 최적화

- + 동일 수준의 응답 품질이 예상되는 경우, Latency 및 Cost 효율이 높은 모델을 우선 선택한다.

9.3. 서비스 기능별 검증 기준

서비스 기능	우선 고려 요소	주요 검증 기준	핵심 지표
일반 FAQ	Latency	빠른 응답 및 기본 정확도	Accuracy, Latency
실시간 운영 챗봇	SLA	timeout 및 응답 안정성	p95 Latency, Timeout Rate
일반 업무 QA	Balanced	정확도 및 응답 품질	Accuracy, Latency, Human Review
정책/규정 QA	Accuracy	근거 기반 정확도	Groundedness, Accuracy
보고서 생성	Reasoning	논리 흐름 및 응답 품질	Completeness, Output Quality, Human Review
SQL/JSON 생성	Structured Output	형식 안정성 및 실행 가능성	Parse Success, Format Validation
문서 요약	Balanced	핵심 내용 유지 여부	Coverage, Summary Quality
RAG 기반 QA	Context 유지	문서 기반 응답 여부	Retrieval Hit Rate, Groundedness
회의록 분석	Context 유지	긴 문맥 유지 및 정보 추출	Extraction Accuracy, Context Validation
재검증 요청	Reliability	응답 신뢰성 및 correction	Reliability, Correction Rate